日本語日常会話における相互行為特徴量の定量化指標の提案
——コーパス基本情報および Big Five 性格特性による妥当性検証——

福原 玄 *　　山下 祐一 †　　宗田 卓史 ‡

2026 年 3 月 25 日

概要

本研究は，日本語日常会話コーパス（CEJC）から抽出可能な 18 の相互行為特徴量——発話タイミング（PG），フィラー（FILL），相互行為構造（IX），応答型（RESP）——を定量化指標として提案し，その妥当性をコーパス基本情報および Big Five 性格特性との関連から検証する．CEJC home2 サブセットの高品質会話 120 件（会話 × 話者ペア）を対象に，まず 18 特徴量の分布特性とカテゴリ内・カテゴリ間の相関構造を記述した．次に，コーパス基本情報（性別・年齢）との関連分析により，発話率やフィラー使用率が性別・年齢と有意に関連することを確認し，特徴量の表面的妥当性を示した．さらに，4 つの大規模言語モデル（LLM）が推定した Big Five スコアを外部基準として Ridge 回帰（5-fold CV, subject-wise split）と置換検定（5000 回）を適用した結果，Conscientiousness（C: 誠実性）は 4 教師中 3 教師で有意な予測精度を示し（$r = 0.390$–0.447, $p < 0.002$），教師間一致度も $\bar{r} = 0.699$ と最も高かった．Bootstrap 安定性分析により，フィラー出現率・質問直後 OIR 率・発話率が C の主要な関連因子として同定された．本研究は，「性格推定モデルの構築」ではなく「日本語会話における相互行為特徴量の定量化指標の提案」として位置づけられ，日本語会話コーパスにおける初の体系的な特徴量提案・検証研究である．

1　はじめに

会話における相互行為——発話のタイミング，言い淀み，応答の型，修復——は，話者の社会的・認知的特性を反映する重要な手がかりである．会話分析（Conversation Analysis）の伝統では，これらの現象は質的に記述されてきたが，大規模コーパスを対象とした定量的・再現可能な計測手法は十分に確立されていない．本研究は，日本語日常会話コーパス（CEJC）を対象に，**相互**

* 筆頭著者．合同会社 Lead lea（リーレア）．連絡先: genfukuhara@leadlea.com
† 国立精神・神経医療研究センター（NCNP）神経研究所 疾病研究第七部
‡ 国立精神・神経医療研究センター（NCNP）

行為特徴量の定量化指標を提案し，その妥当性を複数の外部基準から検証することを目的とする．

近年，大規模言語モデル（LLM）の発展に伴い，会話テキストから ASD 関連指標や性格特性を推定する試みが増加している．Hu ら [1] は，ADOS-2 の対話転記からゼロショット LLM を用いて特定の臨床項目（A4: 常同的言語使用）の有無を推定し，話者分離の品質が推定精度に強く影響することを示した．Altozano ら [2] は，保護者の自由回答から LLM を用いた ASD/TD 二値分類を試み，ネスト CV によるリーク防止設計を採用した．Mun ら [3] は，韓国語の子ども発話から PLM を用いて社会的コミュニケーション重症度の連続値回帰を行い，ASR 誤差やプロンプト設計による性能変動を報告した．国内では，Nakamura ら [4] が ADOS-2 会話テキストから BERT 由来の特徴量と LightGBM を用いた 4 分類を試みている．

しかし，これらの研究には共通する課題がある．第一に，多くの研究が LLM/PLM の出力をそのまま推定値として用いており，会話の相互行為を**再現可能に定量化する指標**の提案には至っていない．すなわち，どのような会話行動が推定に寄与しているかが不透明であり，解釈可能性と再現性に課題が残る．第二に，小標本・非公開データに依存する研究が多く，評価設計の再現性（リーク防止，外部検証，ロバスト性評価）が十分に担保されていない．第三に，日本語会話コーパスを対象とした体系的な特徴量の提案・検証はほとんど行われていない．

本研究は，これらのギャップに対して，以下の貢献を行う．日本語日常会話コーパス（CEJC）から，発話タイミング（PG），フィラー（FILL），相互行為構造（IX），応答型（RESP）の 4 カテゴリにわたる 18 の相互行為特徴量を定量化指標として提案する．**重要な点として，本研究の主たる貢献は特徴量の提案そのものにあり，**Big Five 性格特性との関連分析は，提案指標の構成概念妥当性（construct validity）を検証するための手段として位置づけられる．

提案特徴量の妥当性は，以下の 2 段階で検証する．第一段階（1° ：提案特徴量の抽出）として，18 特徴量の分布特性を記述し（3.1 節），カテゴリ内・カテゴリ間の相関構造を分析する（3.2 節）．第二段階（2° ：外部指標を用いた妥当性検証）として，コーパス基本情報（性別・年齢）との関連から表面的妥当性を確認し（3.3 節），さらに 4 つの LLM 教師が推定した Big Five スコアを外部基準として構成概念妥当性を検証する（3.4 節）．Big5 との関連分析では，subject-wise split によるリーク防止，置換検定（5000 回）による統計的有意性の検証，Bootstrap（500 回）による係数安定性の評価，および複数 LLM 教師間の一致度による頑健性検証を組み合わせた評価設計を採用する．

2 方法

2.1 データ

本研究では，日本語日常会話コーパス（Corpus of Everyday Japanese Conversation; CEJC）の home2 サブセット（自宅・少人数会話）を使用した．品質フィルタ（HQ1: タイミング情報の完全性，発話ペア数の十分性）を適用し，最終的に $N = 120$ の会話 $\times$ 話者ペアを分析対象とした．各レコードは，1 つの会話における 1 人の話者の相互行為特徴量と，LLM 教師が推定した Big

Five スコアの組で構成される．

2.2 特徴量

会話の相互行為を定量化するため，18 の特徴量を 4 つのカテゴリに分類して抽出した．表 1 に各特徴量の名称，カテゴリ，概要，計算アルゴリズムを示す．

表 1　18 特徴量の定義

Name	Cat.	Summary	Algorithm
PG_speech_ratio	PG	Speech ratio	Speaker's total speech time / total conversation time
PG_pause_mean	PG	Mean pause duration	Mean of intra-speaker gaps ($\geq$ gap_tol sec)
PG_pause_p50	PG	Median pause	50th percentile of intra-speaker gaps
PG_pause_p90	PG	90th pctl pause	90th percentile of intra-speaker gaps
PG_resp_gap_mean	PG	Mean response gap	Mean of turn-taking gaps (prev_end $\rightarrow$ resp_start, $\geq$ gap_tol)
PG_resp_gap_p50	PG	Median response gap	50th percentile of turn-taking gaps
PG_resp_gap_p90	PG	90th pctl resp gap	90th percentile of turn-taking gaps
FILL_has_any	FILL	Filler utterance rate	Proportion of utterances containing $\geq$1 filler (etto/ee/ano)
FILL_rate_per_100chars	FILL	Filler rate/100chars	Total fillers / (text length / 100)
IX_oirmarker_rate	IX	OIR marker rate	Proportion of responses starting with OIR markers (e?/eQ/nani?)
IX_oirmarker_after_question_rate	IX	Post-Q OIR rate	OIR rate when previous utterance is a question
IX_yesno_rate	IX	Yes/No response rate	Proportion of responses starting with yes/no prefixes
IX_yesno_after_question_rate	IX	Post-Q Yes/No rate	Yes/No rate when previous utterance is a question
IX_lex_overlap_mean	IX	Lexical overlap	Mean char-bigram Jaccard between prev and response
IX_topic_drift_mean	IX	Topic drift	1 − IX_lex_overlap_mean
RESP_NE_AIZUCHI_RATE	RESP	Post-NE aizuchi rate	Aizuchi rate after NE sentence-final particle
RESP_NE_ENTROPY	RESP	Post-NE response entropy	Shannon entropy of response-initial tokens after NE
RESP_YO_ENTROPY	RESP	Post-YO response entropy	Shannon entropy of response-initial tokens after YO

特徴量は以下の 4 カテゴリに大別される．

■PG（Prosodic/Gap: タイミング系，7 変数）　発話率（PG_speech_ratio）は話者の総発話時間を会話全体時間で除して算出する．沈黙系指標（PG_pause_mean/p50/p90）は，同一話者の連続発話間に生じるギャップのうち，閾値（gap_tol）秒以上のものを対象に平均・中央値・90 パーセンタイルを計算する．応答遅れ系指標（PG_resp_gap_mean/p50/p90）は，話者交替時の前発話終了から応答開始までのギャップについて同様の統計量を算出する．

■FILL（Filler: フィラー系，2 変数）　FILL_has_any は，フィラー（「えっと」「えー」「あの」）を 1 つ以上含む発話の割合である．FILL_rate_per_100chars は，フィラー総数をテキスト文字数の 100 分の 1 で除した正規化指標である．

■IX（Interaction: 相互行為系，6 変数）　修復開始（OIR）率（IX_oirmarker_rate）は，OIR マーカー（「え？」「えっ」「なに？」等）で始まる応答の割合である．IX_oirmarker_after_question_rate は，前発話が質問である場合に限定した OIR 率である．YES/NO 応答率（IX_yesno_rate, IX_yesno_after_question_rate）は，YES/NO プレフィックス（「はい」「うん」「いいえ」等）で始まる応答の割合を，全応答および質問直後応答について算出する．語彙重なり（IX_lex_overlap_mean）は，前発話と応答の文字バイグラム Jaccard 係数の平均であり，話題逸脱度（IX_topic_drift_mean）はその補数（1 − Jaccard）である．

■RESP（Response-typing: 応答型系，3 変数）　RESP_NE_AIZUCHI_RATE は，終助詞「ね」で終わる発話の直後に相槌プレフィックスで始まる応答が出現する割合である．RESP_NE_ENTROPY および RESP_YO_ENTROPY は，それぞれ「ね」「よ」で終わる発話の直後の応答先頭トークンの Shannon entropy であり，応答の多様性を反映する．

■統制変数の除外　回帰分析においては，会話の長さや発話ペア数に依存する統制変数（EXCL3: n_pairs_total, n_pairs_after_NE, n_pairs_after_YO, IX_n_pairs, IX_n_pairs_after_question, PG_total_time, PG_overlap_rate, PG_resp_overlap_rate, FILL_text_len, FILL_cnt_total, FILL_cnt_eto, FILL_cnt_e, FILL_cnt_ano）を説明変数から除外し，上記 18 変数のみを用いた．

■欠損値の処理　特徴量の計算において，分母がゼロとなる場合（例: 質問直後の発話ペアが 0 件の場合の IX_oirmarker_after_question_rate）は NaN とした．回帰パイプラインでは，SimpleImputer（strategy="median"）により中央値で補完した．

18 特徴量の記述統計は 3.1 節（表 3）に示す．

2.3　仮想教師プロトコル

Big Five 性格スコアの目的変数を得るため，4 つの LLM を「仮想教師」として使用した．具体的には，IPIP-NEO-120（International Personality Item Pool, 日本語版 120 項目）の各項目について，会話テキストを参照しながら LLM に 5 件法で回答させ，5 つの性格次元（Openness: O, Conscientiousness: C, Extraversion: E, Agreeableness: A, Neuroticism: N）のスコアを算

出した．

使用した 4 モデルは以下の通りである:

- Sonnet4（Anthropic Claude Sonnet 4）
- Qwen3-235B（Alibaba Qwen3, 235B パラメータ）
- DeepSeek-V3（DeepSeek V3）
- GPT-OSS-120B（OpenAI 系オープンソース, 120B パラメータ）

各モデルは AWS Bedrock 経由で推論を実行し，同一の会話 × 話者ペアに対して独立にスコアを付与した．これにより，特定の LLM に依存しない頑健性の検証が可能となる．

2.4 回帰モデル

18 の相互行為特徴量を説明変数，LLM 教師が推定した Big Five スコアを目的変数として，Ridge 回帰モデルを構築した．正則化パラメータ α は事前に固定し（$\alpha = 100$），5-fold 交差検証（subject-wise split: 同一話者のデータが訓練・テストに分割されないよう制御）により予測精度を評価した．予測精度の指標として，5-fold の予測値と実測値の Pearson 相関係数 r を用いた．

2.5 信頼性検証

■置換検定（Permutation test） 目的変数を 5000 回ランダムにシャッフルし，各シャッフルにおける Ridge 回帰の交差検証相関係数を算出した．観測された相関係数 r_{obs} 以上の値が偶然得られる確率を p 値として報告する．

■Bootstrap 安定性分析 500 回の Bootstrap リサンプリングを行い，各特徴量の回帰係数の安定性を評価した．具体的には，各特徴量について以下の指標を算出した: (i) Top-K inclusion rate（topk_rate）: Bootstrap 反復において Top-K 特徴量に選ばれる頻度，(ii) 符号一致率（sign_agree_rate）: 係数の符号が Bootstrap 反復間で一致する頻度．

3 結果

本節では，提案する 18 の相互行為特徴量について，まず特徴量自体の記述的性質（分布・相関構造）を報告し（3.1–3.2 節），次に外部指標を用いた妥当性検証（コーパス基本情報・Big5 性格特性との関連）を報告する（3.3–3.4 節）．

3.1 提案特徴量の記述統計と分布

表 3 に，18 特徴量の拡張記述統計（N，平均，標準偏差，最小値，四分位点，90 パーセンタイル，最大値）を示す．なお，RESP 系 3 変数（RESP_NE_AIZUCHI_RATE, RESP_NE_ENTROPY, RESP_YO_ENTROPY）は分母となる終助詞ペアが存在しない話者で欠損（NaN）が生じるため，

有効 N がそれぞれ 115, 115, 118 と全体（120）より少ない．

表 3　18 特徴量の拡張記述統計

Feature	N	Mean	SD	Min	p25	p50	p75	p90	Max
PG_speech_ratio	120	0.403	0.144	0.146	0.285	0.384	0.495	0.626	0.767
PG_pause_mean	120	2.702	1.134	0.889	1.739	2.719	3.453	4.046	6.761
PG_pause_p50	120	1.556	0.556	0.526	1.128	1.544	1.948	2.343	2.773
PG_pause_p90	120	6.253	2.840	1.815	4.047	5.966	7.789	9.151	16.700
PG_resp_gap_mean	120	1.098	0.453	0.369	0.783	0.993	1.384	1.763	2.684
PG_resp_gap_p50	120	0.544	0.189	0.200	0.413	0.520	0.643	0.791	1.234
PG_resp_gap_p90	120	2.531	1.215	0.866	1.698	2.231	3.168	4.324	7.756
FILL_has_any	120	0.040	0.030	0.003	0.019	0.035	0.052	0.073	0.179
FILL_rate_per_100chars	120	0.365	0.224	0.039	0.185	0.308	0.512	0.657	1.088
IX_oirmarker_rate	120	0.004	0.007	0.000	0.000	0.000	0.005	0.013	0.029
IX_oirmarker_after_question_rate	120	0.007	0.016	0.000	0.000	0.000	0.000	0.031	0.088
IX_yesno_rate	120	0.235	0.115	0.031	0.150	0.229	0.298	0.377	0.627
IX_yesno_after_question_rate	120	0.309	0.150	0.000	0.219	0.307	0.409	0.468	0.923
IX_lex_overlap_mean	120	0.042	0.023	0.003	0.025	0.039	0.054	0.073	0.114
IX_topic_drift_mean	120	0.958	0.023	0.886	0.946	0.961	0.975	0.983	0.997
RESP_NE_AIZUCHI_RATE	115	0.441	0.229	0.000	0.250	0.457	0.625	0.745	1.000
RESP_NE_ENTROPY	115	2.619	0.909	-0.000	2.000	2.725	3.245	3.694	4.718
RESP_YO_ENTROPY	118	1.924	1.182	-0.000	1.000	1.922	2.794	3.377	4.856

図 1 に，18 特徴量の分布をカテゴリ別に示す．PG 系特徴量（タイミング系 7 変数）は概ね右裾の長い分布を示し，特に PG_pause_p90（$M = 6.253$, $SD = 2.840$）は個人差が大きい．発話率（PG_speech_ratio: $M = 0.403$, $SD = 0.144$）は比較的対称な分布を示し，話者間で適度なばらつきが確認された．

FILL 系特徴量（フィラー系 2 変数）は右に偏った分布を示すが，全話者がゼロでない値を持ち（FILL_has_any: min = 0.003），フィラー使用の個人差を捉える指標として有用である．

IX 系特徴量（相互行為系 6 変数）のうち，OIR 関連指標（IX_oirmarker_rate: $M = 0.004$, IX_oirmarker_after_question_rate: $M = 0.007$）は大半の話者でゼロまたは極めて低い値を示し，分布が強く右に偏っている．これらの特徴量は，修復開始行動が生じた話者を検出する二値的な性質を持つ点に留意が必要である．一方，YES/NO 応答率（IX_yesno_rate: $M = 0.235$, $SD = 0.115$）は適度なばらつきを持つ連続的な分布を示した．IX_lex_overlap_mean（$M = 0.042$）と IX_topic_drift_mean（$M = 0.958$）は定義上の補数関係（1 − Jaccard）にあり，分布は鏡像的である．

RESP 系特徴量（応答型系 3 変数）は，RESP_NE_AIZUCHI_RATE（$M = 0.441$, $SD = 0.229$）が比較的広い範囲に分布し，「ね」に対する応答パターンの個人差を反映している．RESP_NE_ENTROPY（$M = 2.619$）および RESP_YO_ENTROPY（$M = 1.924$）は応答の多様性を示すエントロピー指標であり，いずれも適度なばらつきを持つ．

全体として，18 特徴量の多くは個人差を捉えるのに十分なばらつきを示しており，相互行為の定量化指標として有用であることが確認された．ただし，OIR 関連指標のように分布が極端に偏る特徴量については，解釈上の注意が必要である．

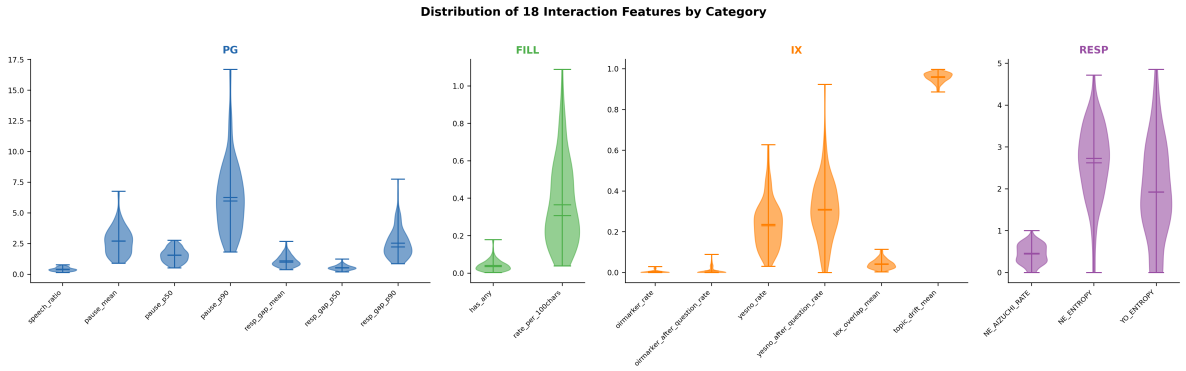

図 1　18 特徴量の分布（カテゴリ別）．PG: タイミング系，FILL: フィラー系，IX: 相互行為系，RESP: 応答型系．

3.2　特徴量カテゴリ内・カテゴリ間の相関分析

表 4 に 18 特徴量間の Pearson 相関行列を，図 2 にカテゴリ別ブロック構造のヒートマップを示す．

■カテゴリ内相関　PG 系特徴量では，沈黙系指標間（PG_pause_mean / PG_pause_p50 / PG_pause_p90）に $r = 0.78$–0.97 の高い正の相関が認められた．これらは同一の構成概念（話者内沈黙の長さ）の異なる集約統計量であり，高い相関は理論的に整合する．同様に，応答遅れ系指標間（PG_resp_gap_mean / PG_resp_gap_p50 / PG_resp_gap_p90）にも $r = 0.61$–0.94 の高い相関が認められた．発話率（PG_speech_ratio）は沈黙系指標と強い負の相関（$r = -0.77$〜-0.85）を示し，発話率が高い話者ほど沈黙が短いという直感的な関係が確認された．

FILL 系特徴量では，FILL_has_any（フィラー出現発話率）と FILL_rate_per_100chars（100 文字あたりフィラー率）の間に $r = 0.85$ の高い相関が認められた．両指標はフィラー使用の異なる正規化方法であり，高い相関は妥当である．

IX 系特徴量では，IX_oirmarker_rate と IX_oirmarker_after_question_rate の間に $r = 0.71$ の相関が認められた．IX_yesno_rate と IX_yesno_after_question_rate の間にも $r = 0.82$ の高い相関があり，全応答と質問直後応答で類似した傾向を示す．IX_lex_overlap_mean と IX_topic_drift_mean は定義上 $r = -1.00$ の完全な負の相関を持つ（topic_drift = 1− lex_overlap）．この完全共線性

表 4　18 特徴量間の Pearson 相関行列．カテゴリ順: PG（1–7），FILL（8–9），IX（10–15），RESP（16–18）．

	1	2	3	4	5	6	7	8	9	10	11	12	13
(1) PG_speech_ratio	—	-0.83	-0.85	-0.77	-0.44	-0.28	-0.36	0.61	0.48	-0.06	-0.04	-0.05	0.03
(2) PG_pause_mean	-0.83	—	0.86	0.97	0.61	0.40	0.56	-0.38	-0.40	-0.02	0.01	0.03	0.01
(3) PG_pause_p50	-0.85	0.86	—	0.78	0.44	0.35	0.37	-0.40	-0.36	0.02	0.14	0.09	0.00
(4) PG_pause_p90	-0.77	0.97	0.78	—	0.58	0.39	0.55	-0.34	-0.38	-0.06	-0.03	0.04	0.02
(5) PG_resp_gap_mean	-0.44	0.61	0.44	0.58	—	0.71	0.94	-0.13	-0.24	-0.05	-0.09	-0.25	-0.08
(6) PG_resp_gap_p50	-0.28	0.40	0.35	0.39	0.71	—	0.61	-0.06	-0.14	0.04	0.05	-0.35	-0.18
(7) PG_resp_gap_p90	-0.36	0.56	0.37	0.55	0.94	0.61	—	-0.09	-0.21	-0.08	-0.13	-0.24	-0.05
(8) FILL_has_any	0.61	-0.38	-0.40	-0.34	-0.13	-0.06	-0.09	—	0.85	-0.07	-0.02	0.08	0.11
(9) FILL_rate_per_100chars	0.48	-0.40	-0.36	-0.38	-0.24	-0.14	-0.21	0.85	—	0.01	0.04	0.21	0.20
(10) IX_oirmarker_rate	-0.06	-0.02	0.02	-0.06	-0.05	0.04	-0.08	-0.07	0.01	—	0.71	-0.12	-0.11
(11) IX_oirmarker_after_question_rate	-0.04	0.01	0.14	-0.03	-0.09	0.05	-0.13	-0.02	0.04	0.71	—	-0.03	-0.06
(12) IX_yesno_rate	-0.05	0.03	0.09	0.04	-0.25	-0.35	-0.24	0.08	0.21	-0.12	-0.03	—	0.82
(13) IX_yesno_after_question_rate	0.03	0.01	0.00	0.02	-0.08	-0.18	-0.05	0.11	0.20	-0.11	-0.06	0.82	—
(14) IX_lex_overlap_mean	0.09	-0.17	-0.11	-0.17	-0.08	-0.12	-0.09	-0.02	0.03	-0.02	-0.04	-0.04	-0.10
(15) IX_topic_drift_mean	-0.09	0.17	0.11	0.17	0.08	0.12	0.09	0.02	-0.03	0.02	0.04	0.04	0.10
(16) RESP_NE_AIZUCHI_RATE	0.00	0.05	0.03	0.08	-0.05	-0.21	-0.05	0.15	0.18	-0.02	0.08	0.47	0.30
(17) RESP_NE_ENTROPY	0.13	-0.16	-0.21	-0.15	-0.14	-0.06	-0.07	0.02	0.06	-0.12	-0.12	-0.06	0.12
(18) RESP_YO_ENTROPY	-0.12	-0.01	-0.10	-0.01	-0.04	-0.07	-0.07	-0.18	-0.06	0.12	0.03	-0.16	-0.11

Column key: (1) PG_speech_ratio, (2) PG_pause_mean, (3) PG_pause_p50, (4) PG_pause_p90, (5) PG_resp_gap_mean, (6) PG_resp_gap_p50, (7) PG_resp_gap_p90, (8) FILL_has_any, (9) FILL_rate_per_100chars, (10) IX_oirmarker_rate, (11) IX_oirmarker_after_question_rate, (12) IX_yesno_rate, (13) IX_yesno_after_question_rate, (14) IX_lex_overlap_mean, (15) IX_topic_drift_mean, (16) RESP_NE_AIZUCHI_RATE, (17) RESP_NE_ENTROPY, (18) RESP_YO_ENTROPY

は回帰分析において留意が必要であるが，Ridge 回帰の正則化により推定の安定性は確保されている．

RESP 系特徴量では，RESP_NE_ENTROPY と RESP_YO_ENTROPY の間に $r = 0.29$ の弱い正の相関が認められた程度であり，3 変数間の相関は全体的に低い．

■カテゴリ間相関　カテゴリ間の相関は概ね低く（$|r| < 0.30$），4 つのカテゴリが相互に独立した側面を捉えていることが示された．例外として，PG_speech_ratio と FILL_has_any の間に $r = 0.61$ のやや高い正の相関が認められた．これは，発話率の高い話者ほどフィラーを含む発話が多いことを反映しており，発話量の多さがフィラー出現機会を増やすという解釈が可能である．

■多重共線性への含意　同一カテゴリ内の高い相関（特に PG 系の沈黙・応答遅れ指標間）は，通常の最小二乗回帰では多重共線性の問題を引き起こしうる．本研究では Ridge 回帰（$\alpha = 100$）を採用しており，正則化により係数推定の安定性が確保されている．また，IX_lex_overlap_mean と IX_topic_drift_mean の完全共線性（$r = -1.00$）についても，Ridge 回帰の L_2 正則化により推定が破綻することはない．ただし，個々の特徴量の係数解釈には，これらの相関構造を考慮する必要がある．

3.3　コーパス基本情報との関連性

特徴量の妥当性を外部指標から検証するため，コーパスに付随する話者属性情報（性別・年齢）と 18 特徴量の関連を分析した．話者属性は CEJC メタ情報（話者.csv，話者・会話対応表.csv）か

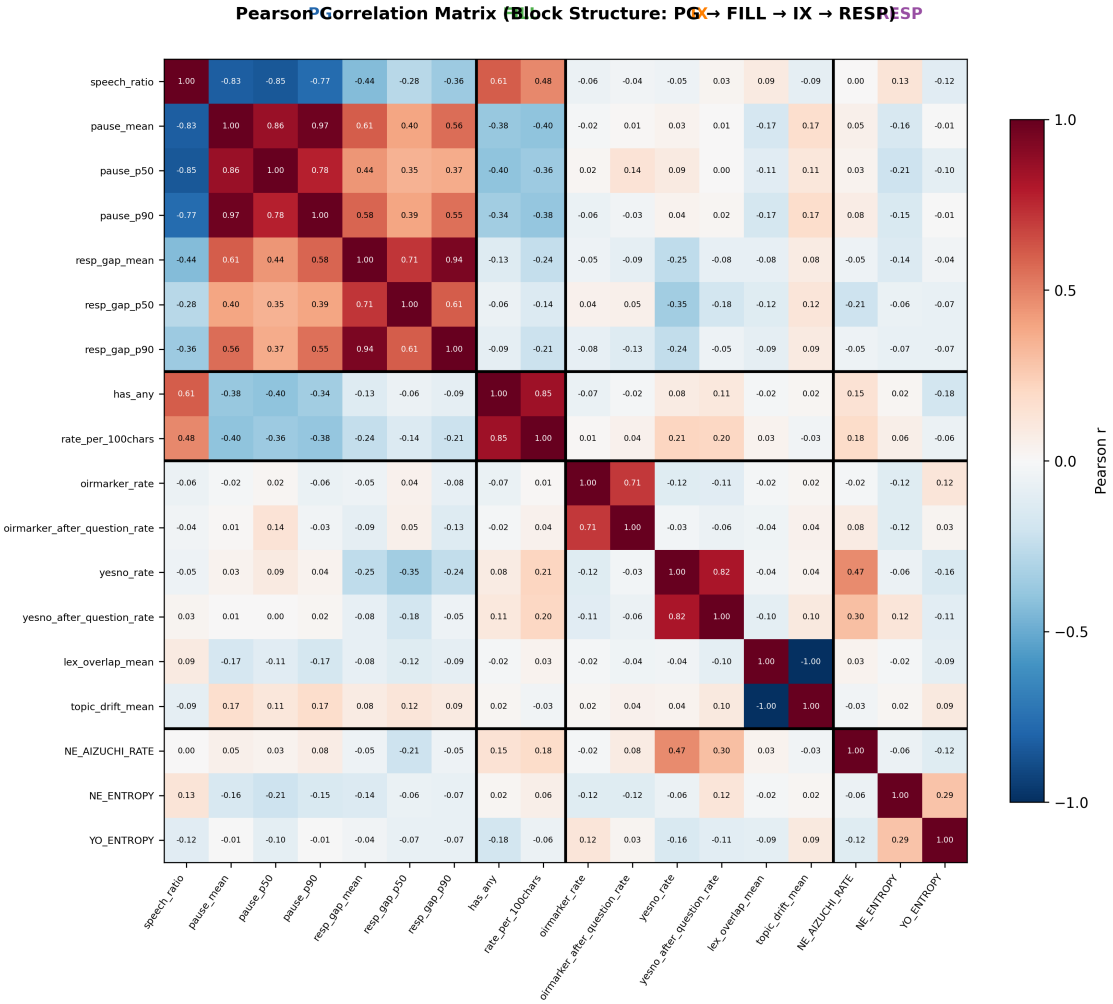

図 2　特徴量間相関行列のヒートマップ（カテゴリ別ブロック構造）．実線はカテゴリ境界を示す．

ら conversation_id × speaker_id をキーに紐付けた（$N = 120$ 全件マッチ，女性 66 名・男性 54 名）．表 5 に，性別の Mann-Whitney U 検定および年齢との相関分析（Pearson r，Spearman ρ）の結果を示す．

■性別との関連　7 つの特徴量で性別間に有意差が認められた（図 3）．PG 系タイミング指標では，PG_speech_ratio（$U = 950$, $p < 0.0001$），PG_pause_mean（$U = 2645$, $p < 0.0001$），PG_pause_p50（$U = 2740$, $p < 0.0001$），PG_pause_p90（$U = 2647$, $p < 0.0001$）に強い有意差が認められ，女性の方が発話率が高く沈黙が短い傾向を示した．FILL_has_any（$U = 1406$, $p = 0.048$）は女性の方がフィラー出現発話率が高かった．IX 系では，IX_lex_overlap_mean（$U = 1109$, $p = 0.0004$）は女性の方が語彙重なりが高く，IX_topic_drift_mean（$U = 2455$, $p = 0.0004$）は男性の方が話題逸脱度が高かった．これらの結果は，女性の方が発話率が高く相手の発話を拾って応答する傾向があるという社会言語学的に既知の知見と整合する．

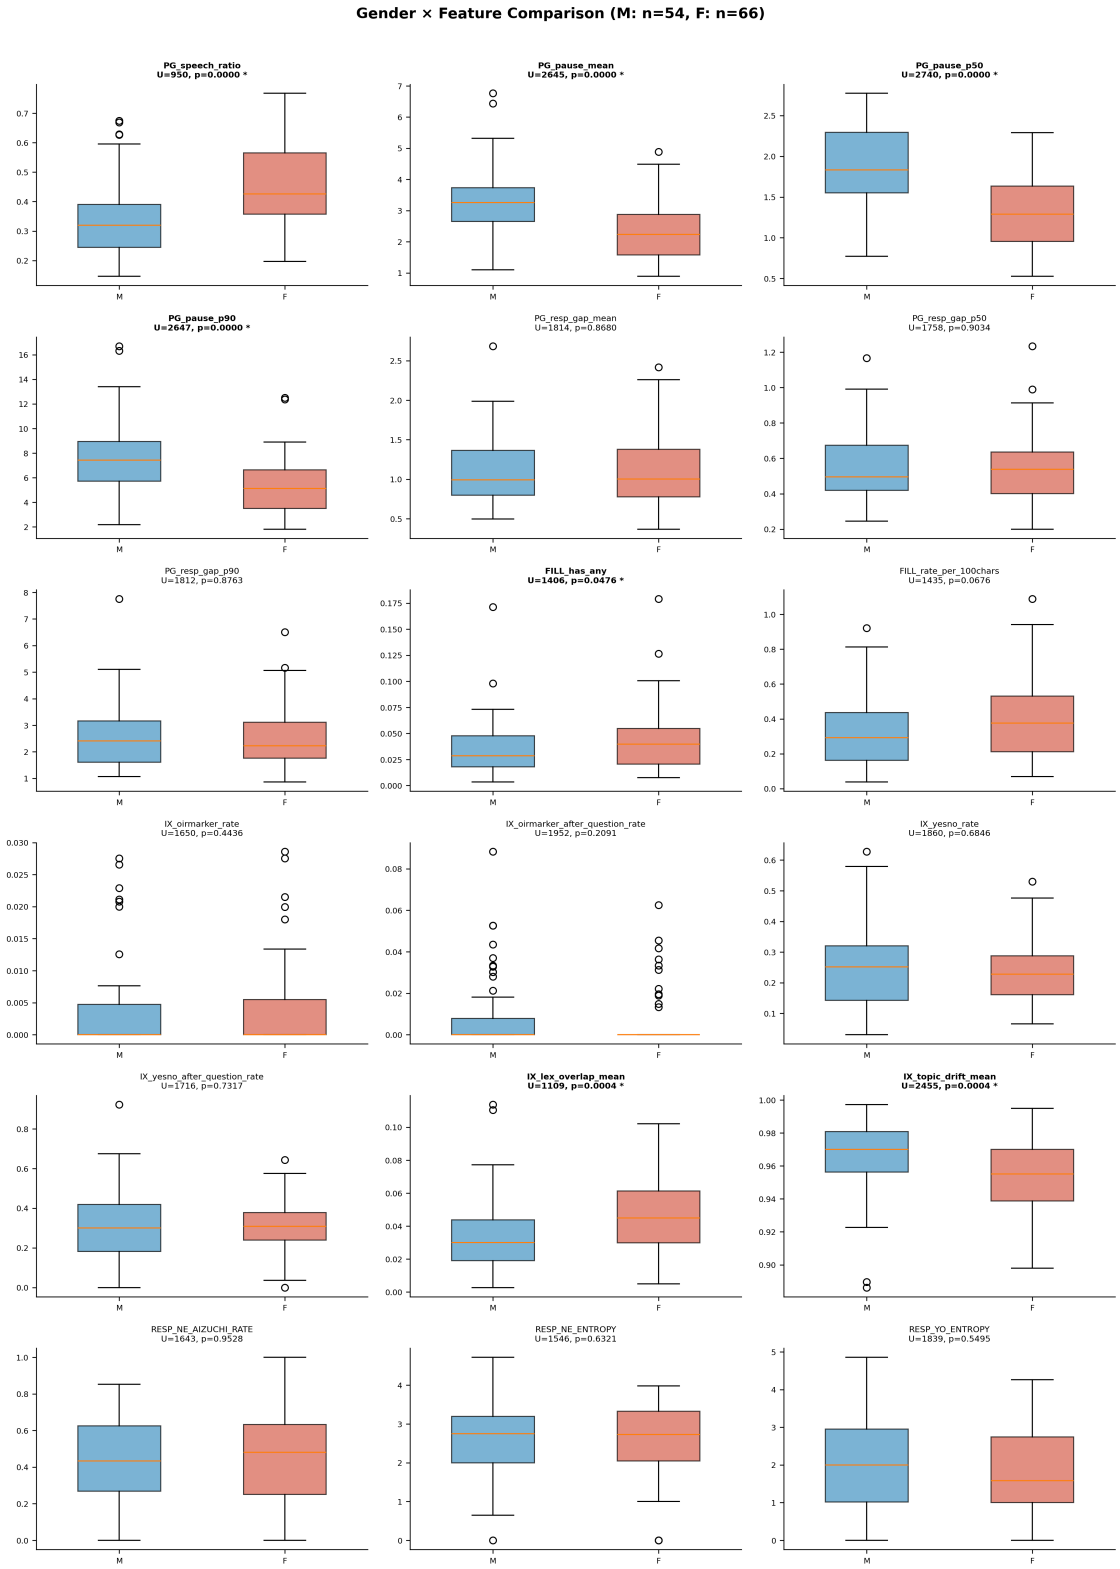

図 3　性別と特徴量の関連（箱ひげ図 + Mann-Whitney U 検定結果）．M: 男性（$n = 54$），F: 女性（$n = 66$）．$*$ は $p < 0.05$ を示す．

表 5　18 特徴量とコーパス基本情報（性別・年齢）の関連分析．太字は $p < 0.05$ を示す．性別: Mann-Whitney U 検定（M: $n = 54$, F: $n = 66$），年齢: 5 歳刻みバンドの中央値（2–82 歳, $M = 42.2$ 歳）を使用.

Feature	U	p_{gender}	r_{Pearson}	p_{Pearson}	ρ_{Spearman}	p_{Spearman}
PG_speech_ratio	**950**	**0.0000***	**0.455**	**0.0000***	**0.447**	**0.0000***
PG_pause_mean	**2645**	**0.0000***	**-0.332**	**0.0002***	**-0.389**	**0.0000***
PG_pause_p50	**2740**	**0.0000***	**-0.436**	**0.0000***	**-0.449**	**0.0000***
PG_pause_p90	**2647**	**0.0000***	**-0.275**	**0.0024***	**-0.343**	**0.0001***
PG_resp_gap_mean	1814	0.8680	**-0.238**	**0.0087***	**-0.241**	**0.0080***
PG_resp_gap_p50	1758	0.9034	**-0.289**	**0.0013***	**-0.256**	**0.0047***
PG_resp_gap_p90	1812	0.8763	**-0.212**	**0.0204***	**-0.200**	**0.0285***
FILL_has_any	**1406**	**0.0476***	**0.445**	**0.0000***	**0.442**	**0.0000***
FILL_rate_per_100chars	1435	0.0676	**0.415**	**0.0000***	**0.391**	**0.0000***
IX_oirmarker_rate	1650	0.4436	-0.104	0.2592	-0.105	0.2549
IX_oirmarker_after_question_rate	1952	0.2091	-0.076	0.4093	-0.102	0.2699
IX_yesno_rate	1860	0.6846	**0.252**	**0.0055***	**0.249**	**0.0060***
IX_yesno_after_question_rate	1716	0.7317	**0.296**	**0.0010***	**0.279**	**0.0020***
IX_lex_overlap_mean	**1109**	**0.0004***	-0.115	0.2116	-0.126	0.1706
IX_topic_drift_mean	**2455**	**0.0004***	0.115	0.2116	0.126	0.1706
RESP_NE_AIZUCHI_RATE	1643	0.9528	**0.272**	**0.0033***	**0.289**	**0.0017***
RESP_NE_ENTROPY	1546	0.6321	0.030	0.7542	0.059	0.5286
RESP_YO_ENTROPY	1839	0.5495	-0.087	0.3482	-0.027	0.7685

■年齢との関連　12 の特徴量で年齢と有意な相関が認められた（図 4）．PG_speech_ratio（$r = 0.455$, $p < 0.0001$）は年齢と強い正の相関を示し，年齢が高い話者ほど発話率が高い傾向が確認された．沈黙系指標（PG_pause_mean: $r = -0.332$; PG_pause_p50: $r = -0.436$; PG_pause_p90: $r = -0.275$）および応答遅れ系指標（PG_resp_gap_mean: $r = -0.238$; PG_resp_gap_p50: $r = -0.289$; PG_resp_gap_p90: $r = -0.212$）は年齢と有意な負の相関を示し，年齢が高い話者ほど沈黙・応答遅れが短い傾向が認められた．FILL 系指標（FILL_has_any: $r = 0.445$; FILL_rate_per_100chars: $r = 0.415$）は年齢と強い正の相関を示し，年齢が高い話者ほどフィラー使用が多い傾向が確認された．IX 系では，IX_yesno_rate（$r = 0.252$）および IX_yesno_after_question_rate（$r = 0.296$）が年齢と有意な正の相関を示し，年齢が高い話者ほど YES/NO 応答が多い傾向が認められた．RESP_NE_AIZUCHI_RATE（$r = 0.272$, $p = 0.003$）も年齢と有意な正の相関を示し，年齢が高い話者ほど「ね」直後の相槌が多い傾向が確認された．

■妥当性の含意　18 特徴量のうち 12 特徴量が年齢と，7 特徴量が性別と有意な関連を示した．特に PG 系（タイミング）と FILL 系（フィラー）は性別・年齢の両方と強い関連を持ち，社会言語学的に既知の知見と整合する結果が得られた．これらの結果は，提案特徴量の**表面的妥当性（face validity）**を強く支持する．

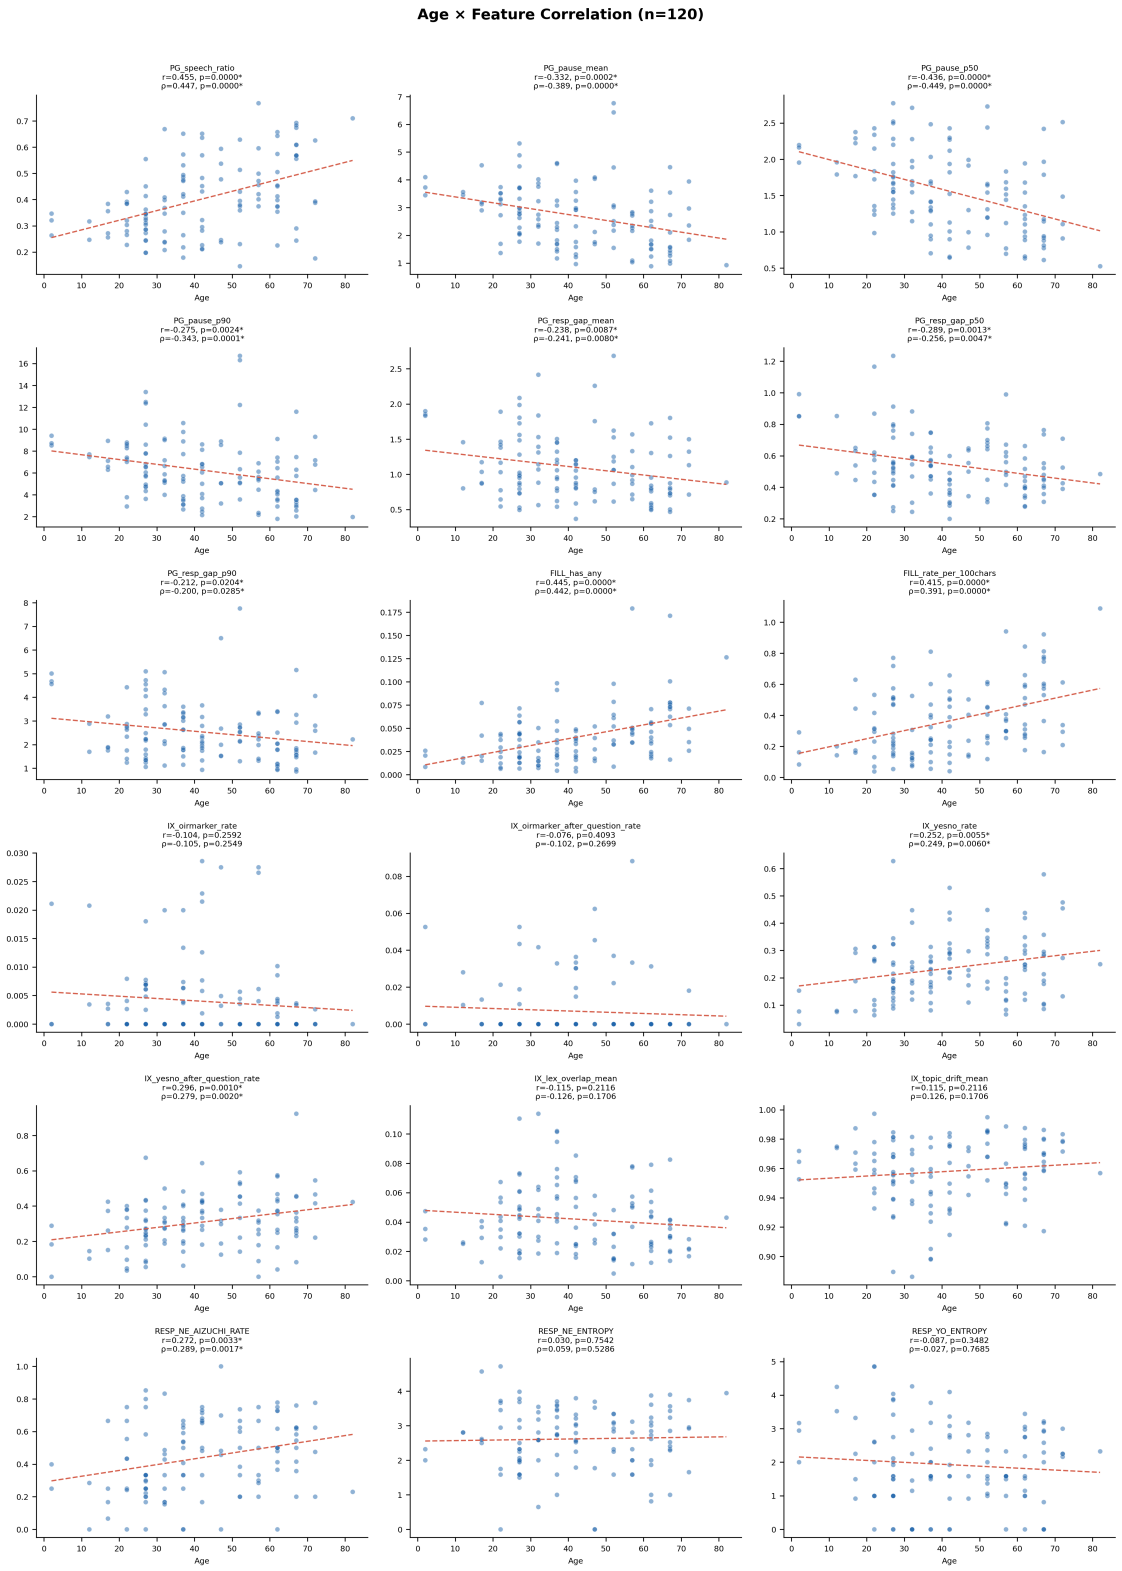

図 4　年齢と特徴量の関連（散布図 + 回帰直線）．各点は 1 話者を表す．Pearson r および Spearman ρ（p 値）を付記.

3.4 性格特性（Big5）との関連性

本節では，提案特徴量と外部の心理学的構成概念（Big Five 性格特性）との関連を報告する．**本分析は特徴量の構成概念妥当性（construct validity）の検証であり，性格推定モデルの構築を目的としない．**すなわち，相互行為特徴量が心理学的に意味のある個人差次元と関連するかどうかを検証することで，指標としての有用性を裏付けるものである．

3.4.1 Conscientiousness の頑健性（Permutation test）

表 6 に，5 つの Big Five 次元 ×4 教師の置換検定結果を示す．Conscientiousness（C: 誠実性）は，4 教師中 3 教師で有意な予測精度を示した: Sonnet4（$r = 0.434$, $p = 0.0008$），Qwen3-235B（$r = 0.390$, $p = 0.0010$），GPT-OSS-120B（$r = 0.447$, $p = 0.0008$）．DeepSeek-V3 のみ有意水準に達しなかった（$r = 0.205$, $p = 0.1130$）．この結果は，C の予測可能性が特定の LLM 教師に依存しない頑健な知見であることを示唆し，相互行為特徴量が C という性格次元と安定的に関連することを示す．

表 6　置換検定結果: 観測相関係数 r_{obs}（p 値）．太字は $p < 0.05$ を示す．

Trait	Sonnet4	Qwen3-235B	GPT-OSS-120B	DeepSeek-V3
C	**0.434 (0.0008)**	**0.390 (0.0010)**	**0.447 (0.0008)**	0.205 (0.1130)
A	0.234 (0.0714)	**0.365 (0.0032)**	**0.461 (0.0002)**	**0.339 (0.0070)**
E	0.226 (0.0804)	**0.300 (0.0224)**	**0.257 (0.0460)**	0.136 (0.3033)
N	0.112 (0.3975)	0.239 (0.0634)	**0.401 (0.0010)**	0.202 (0.1154)
O	0.119 (0.3587)	**0.350 (0.0060)**	**0.345 (0.0088)**	**0.323 (0.0086)**

図 5 に，C の 4 教師比較バーチャートを示す．3 教師で有意水準を超える相関が観測され，相互行為特徴量が C の推定に一貫して寄与することが視覚的にも確認できる．

3.4.2 教師間一致度

図 6 に，5 次元 ×4 教師の教師間一致度ヒートマップを示す．C の教師間平均相関は $\bar{r} = 0.699$ であり，5 次元中最も高かった．一方，Agreeableness（A: 協調性）は $\bar{r} = 0.435$ と最も低く，教師依存性が大きいことが示された．

C の高い教師間一致度は，前項で示した C の頑健な予測可能性と整合する．すなわち，複数の LLM 教師が C について類似したスコアを付与しており，その一致したスコアが相互行為特徴量によって安定的に予測可能であるという構造が確認された．これは，C に関連する会話行動（フィラー使用，応答の丁寧さ等）が LLM にとって比較的観察しやすい特性であることを示唆する．

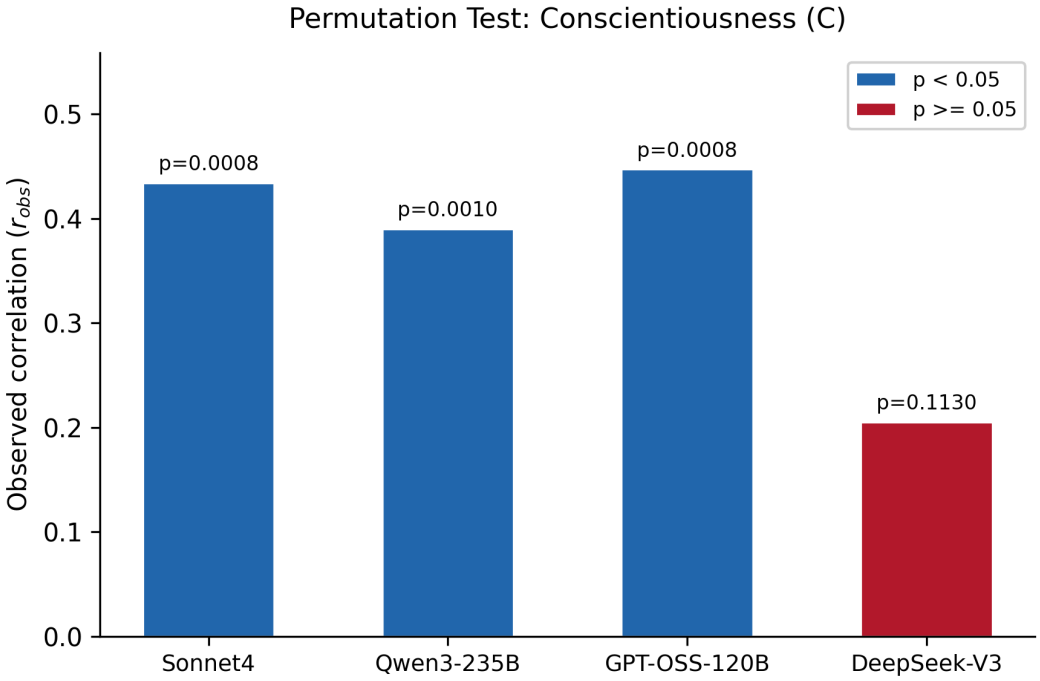

図 5　Conscientiousness の置換検定結果（4 教師比較）．バーは観測相関係数 r_{obs}，括弧内は p 値を示す．破線は有意水準 $p = 0.05$ に対応する参照線．

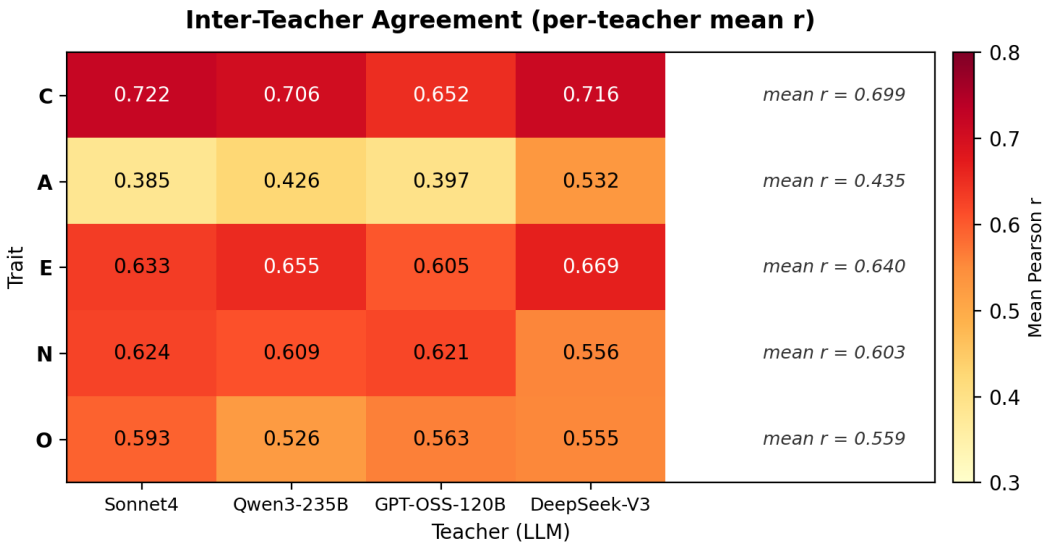

図 6　教師間一致度ヒートマップ（5 次元 ×4 教師）．各セルは Pearson 相関係数を示す．C の平均 $\bar{r} = 0.699$（最高），A の平均 $\bar{r} = 0.435$（最低）．

3.4.3 Bootstrap Top Drivers

図 7 に，C の Bootstrap 安定性分析（Sonnet4 基準）における上位特徴量のレーダーチャートを示す．Top-K inclusion rate と符号一致率の両方が高い特徴量として，以下の 3 変数が同定された:

- FILL_has_any（フィラー出現発話率，正の寄与）
- IX_oirmarker_after_question_rate（質問直後 OIR 率，正の寄与）
- PG_speech_ratio（発話率，正の寄与）

これらの特徴量は，500 回の Bootstrap リサンプリングにおいて一貫して C の予測に寄与しており，係数の符号も安定していた．フィラーの使用頻度，質問に対する修復開始の頻度，および発話率の高さが C の高さと関連するという解釈が，統計的に安定した知見として支持される．

なお，3.3 節で報告したコーパス基本情報との関連分析において，FILL_has_any（フィラー出現発話率）が年齢と強い正の相関（$r = 0.445$）を示した点は注目に値する．この特徴量は C の Top 1 Driver であると同時に年齢とも強く関連しており，フィラー使用が認知的・性格的な個人差の両方を反映する多面的な指標である可能性を示唆する．

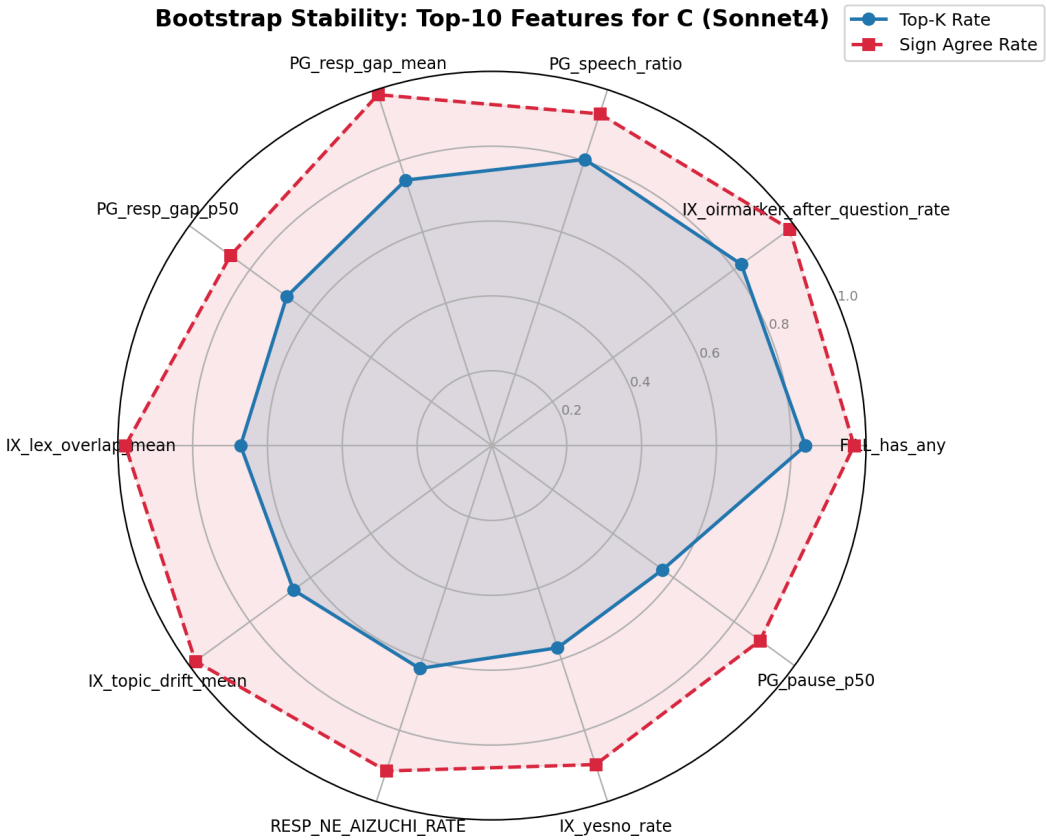

図 7　C の Bootstrap Top 特徴量レーダーチャート（Sonnet4 基準，500 回リサンプリング）．外周は topk_rate，内周は sign_agree_rate を示す．

4　考察

4.1　提案特徴量の記述的性質と相関構造

本研究が提案する 18 の相互行為特徴量は，記述統計の分析（3.1 節）から，多くの特徴量が個人差を捉えるのに十分なばらつきを持つことが確認された．PG 系のタイミング指標や FILL 系のフィラー指標は連続的な分布を示し，話者間の行動差を段階的に反映する定量化指標として機能する．RESP 系特徴量も，「ね」直後相槌率（RESP_NE_AIZUCHI_RATE: $SD = 0.229$）に見られるように，応答パターンの個人差を適切に捉えている．

一方，OIR 関連指標（IX_oirmarker_rate, IX_oirmarker_after_question_rate）は大半の話者でゼロまたは極めて低い値を示し，分布が強く右に偏っている．修復開始行動は日常会話において低頻度の事象であり，この偏りは現象の性質を反映したものである．したがって，OIR 指標は連続的な個人差の指標というよりも，修復開始行動が生じた話者を検出する二値的な性質を持つ指標として解釈すべきである．この性質は，後述する Big5 分析において OIR 率が C の Top Driver として同定された知見の解釈にも影響する——すなわち，OIR 率の寄与は「修復開始行動の頻度の連続的な増加」ではなく，「修復開始行動を行うか否か」という質的な差異を反映している可能性がある．

相関分析（3.2 節）の結果は，提案特徴量セットの構造的妥当性を支持する．同一カテゴリ内の高い相関——PG 系の沈黙指標間（$r = 0.78$–0.97），応答遅れ指標間（$r = 0.61$–0.94），FILL 系の 2 指標間（$r = 0.85$）——は，同一の構成概念（例：話者内沈黙の長さ）の異なる集約統計量であることから理論的に予測される結果であり，特徴量の内的整合性を示している．IX_lex_overlap_mean と IX_topic_drift_mean の完全共線性（$r = -1.00$）は定義上の補数関係に起因するものであり，将来の研究ではいずれか一方のみを使用するか，主成分分析等による次元縮約を検討すべきである．

重要な知見として，カテゴリ間の相関は概ね低く（$|r| < 0.30$），PG（タイミング），FILL（フィラー），IX（相互行為構造），RESP（応答型）の 4 カテゴリが相互に独立した会話行動の側面を捉えていることが示された．この独立性は，提案特徴量セットが会話の相互行為を多面的に記述する指標体系として機能することの根拠となる．PG_speech_ratio と FILL_has_any の間のやや高い相関（$r = 0.61$）は，発話量の多さがフィラー出現機会を増やすという機構的な関連を反映しており，カテゴリの独立性を本質的に損なうものではない．

4.2　コーパス基本情報との関連の解釈

コーパス基本情報（性別・年齢）との関連分析（3.3 節）は，提案特徴量の表面的妥当性（face validity）を強く支持する知見を提供した．

性別との関連では，PG 系タイミング指標に顕著な性差が認められた．女性の方が発話率が高く（$U = 950$, $p < 0.0001$），沈黙が短い傾向は，社会言語学における既知の知見——女性は会話において積極的に発話し，沈黙を短く保つ傾向がある——と整合する．IX_lex_overlap_mean（語彙重なり）の性差（$p = 0.0004$）は，女性の方が相手の発話を拾って応答する傾向が強いことを示唆し，

相互行為における協調的スタイルの性差を反映している可能性がある．

年齢との関連では，18 特徴量中 12 特徴量で有意な相関が認められ，特に PG 系と FILL 系で強い効果が観察された．PG_speech_ratio（発話率）と年齢の強い正の相関（$r = 0.455$）は，年齢が高い話者ほど会話への参加が積極的であることを示す．沈黙系・応答遅れ系指標と年齢の負の相関は，年齢が高い話者ほどテンポよく応答する傾向を反映しており，会話経験の蓄積による流暢さの向上として解釈可能である．FILL 系指標と年齢の強い正の相関（$r \approx 0.4$）は，年齢が高い話者ほどフィラーを多用する傾向を示し，発話計画コストの増大や丁寧な発話スタイルの反映として解釈できる．RESP_NE_AIZUCHI_RATE（「ね」直後相槌率）と年齢の正の相関（$r = 0.272$）は，年齢が高い話者ほど共感的な応答パターンを示す傾向を反映している可能性がある．

注目すべきは，FILL_has_any（フィラー出現発話率）が年齢と強い正の相関（$r = 0.445$）を示すと同時に，Big5 分析（3.4.3 節）において C の Bootstrap Top 1 Driver としても同定されている点である．この交差的な知見は，フィラー使用が認知的側面（加齢に伴う発話計画コスト）と性格的側面（誠実性に関連する慎重な発話スタイル）の両方を反映する多面的な指標であることを示唆する．この多面性は，提案特徴量が単一の構成概念に還元されない豊かな情報を持つことの証左であると同時に，特徴量の解釈においては交絡要因の考慮が必要であることも示している．

なお，メタデータ分析は性別・年齢に限定されており，出身地域（方言）・学歴・職業等の社会言語学的変数との関連は今後の課題である．CEJC メタ情報には出身地・居住地・職業の情報が含まれており，これらの属性情報を用いた追加分析により，特徴量の妥当性をより多角的に検証できると期待される．

4.3 相互行為特徴量と Big5 の関連の解釈

本研究の主要な知見は，会話の相互行為特徴量が Conscientiousness（C: 誠実性）の LLM スコアを頑健に予測することである．Bootstrap 安定性分析で同定された Top 3 特徴量——フィラー出現率（FILL_has_any），質問直後 OIR 率（IX_oirmarker_after_question_rate），発話率（PG_speech_ratio）——はいずれも正の寄与を示した．

フィラー（「えっと」「えー」「あの」）の使用は，発話計画の慎重さや丁寧さの指標として解釈できる．誠実性の高い話者は，発話の正確性を重視するためにフィラーを用いて発話計画の時間を確保する傾向がある可能性がある．質問直後の OIR（Other-Initiated Repair）マーカーの使用は，相手の発話を正確に理解しようとする姿勢を反映しており，これも誠実性の高さと整合する．発話率の高さは，会話への積極的な参加を示し，対話における責任感や関与の深さと関連する可能性がある．

4.4 定量化指標の提案としての位置づけ

本研究の主たる貢献は，日本語日常会話における相互行為特徴量の**定量化指標の提案**にある．先行研究では，談話から LLM/PLM を用いて ASD 関連指標や性格特性を推定する試みが増加して

いるものの（Hu ら [1]; Altozano ら [2]; Mun ら [3]），これらの研究は LLM/PLM の出力をそのまま推定値として用いており，会話の相互行為を**再現可能に定量化する指標**の提案には至っていない．日本語会話コーパスを対象とした体系的な特徴量の提案・検証は，Nakamura ら [4] を含めてもほとんど行われていなかった．

本研究は，この空白を埋めるものとして，以下の方法論的貢献を行う．第一に，18 の相互行為特徴量を 4 カテゴリ（PG, FILL, IX, RESP）に体系化し，各特徴量の計算アルゴリズムを明示的に定義した（2.2 節）．これにより，第三者による再現が可能な指標体系を提供する．

第二に，提案特徴量の妥当性を 2 段階で検証する設計を採用した．第 1 段階（1° ：提案特徴量の抽出）では，特徴量の分布特性（3.1 節）と相関構造（3.2 節）を記述し，指標としての基本的な性質を確認した．第 2 段階（2° ：外部指標を用いた妥当性検証）では，コーパス基本情報との関連（3.3 節）から表面的妥当性を，Big5 性格特性との関連（3.4 節）から構成概念妥当性を検証した．この 2 段階の検証設計は，特徴量の提案研究における方法論的な枠組みとして，他の研究にも適用可能である．

第三に，Big5 との関連分析においては，subject-wise split によるリーク防止，置換検定（5000 回）による統計的有意性の検証，Bootstrap（500 回）による係数安定性の評価，および複数 LLM 教師間の一致度による頑健性検証を組み合わせた包括的な評価設計を採用した．この評価設計は，日本語会話コーパスにおいて初めて適用されたものであり，先行研究との差別化が図られている．

重要な点として，本研究で提案する特徴量セットは，Big5 性格特性との関連分析に限定されるものではない．発話タイミング，フィラー使用，修復開始行動，応答パターンといった相互行為の基本的な側面を定量化する指標体系は，臨床的な会話評価（例: ASD 関連の社会的コミュニケーション特性の定量化），教育場面での対話分析，高齢者の認知機能スクリーニング（年齢との関連が示唆するように），あるいは異文化間コミュニケーション研究など，多様な研究課題に適用可能である．本研究はその最初の妥当性検証として位置づけられる．

4.5 限界

本研究にはいくつかの重要な限界がある．第一に，標本サイズが $N = 120$ と小さく，結果の一般化可能性には制約がある．特に，Ridge 回帰の正則化パラメータの最適化や，より複雑なモデルの適用には不十分なサンプルサイズである．第二に，外部検証（別コーパス・別収録条件でのクロスバリデーション）が未実施であり，CEJC home2 サブセットに特有の結果である可能性を排除できない．第三に，LLM 教師の妥当性そのものが未検証である．本研究では LLM スコアを「仮想教師」として使用しているが，これが人間の性格評定とどの程度一致するかは別途検証が必要である．第四に，C の有意な結果が複数教師で観測された一方で，A/E/N/O の一部でも有意な結果が得られており（表 6 参照），これらの結果には一般因子（general factor）の混入——すなわち，C に寄与する特徴量が他の次元にも影響している可能性——を考慮する必要がある．第五に，コーパス基本情報との関連分析は性別・年齢に限定されており，出身地域（方言）・学歴・職業等の社会的属性との関連は未検討である．CEJC メタ情報にはこれらの属性が含まれており，今後の分析

により特徴量の適用範囲をより詳細に理解できると期待される．

5　結論

本研究は，日本語日常会話コーパス（CEJC home2 HQ1, $N = 120$）から抽出した 18 の相互行為特徴量を用いて，4 つの LLM 教師が推定した Big Five スコアを Ridge 回帰で予測する枠組みを提案し，以下の知見を得た．

第一に，Conscientiousness（C: 誠実性）は 4 教師中 3 教師で有意な予測精度を示し（$r = 0.390$–0.447, $p < 0.002$），特定の LLM 教師に依存しない頑健な知見であった．第二に，C の教師間一致度は $\bar{r} = 0.699$ と 5 次元中最も高く，LLM 教師が C について安定したスコアを付与していることが確認された．第三に，Bootstrap 安定性分析により，フィラー出現率・質問直後 OIR 率・発話率が C の主要な予測因子として同定された．

本研究は，「性格推定」ではなく「会話の相互行為の再現可能な計測」として位置づけられ，日本語会話コーパスにおける初の体系的検証として，今後の研究の基盤となることが期待される．

付録 A　探索的結果: A/E/N/O の置換検定

表 6（本文 3.4 節）に示した置換検定結果には，C 以外の 4 次元（A, E, N, O）の結果も含まれている．本付録では，これらの探索的結果について補足する．

注意: 以下は C 以外の次元に関する探索的結果であり，確認的解釈は避けるべきである．本研究の事前仮説は C の頑健性検証に限定されており，A/E/N/O の結果は多重比較の補正を行っていない探索的知見として位置づけられる．

Agreeableness（A）は，Qwen3-235B（$r = 0.365$, $p = 0.0032$），GPT-OSS-120B（$r = 0.461$, $p = 0.0002$），DeepSeek-V3（$r = 0.339$, $p = 0.0070$）の 3 教師で有意であったが，Sonnet4（$r = 0.234$, $p = 0.0714$）では有意水準に達しなかった．教師間一致度が $\bar{r} = 0.435$ と低いことを考慮すると，A の結果は教師依存性が大きく，解釈には慎重を要する．

Extraversion（E）は，Qwen3-235B（$r = 0.300$, $p = 0.0224$）と GPT-OSS-120B（$r = 0.257$, $p = 0.0460$）で有意であったが，Sonnet4 と DeepSeek-V3 では有意でなかった．

Neuroticism（N）は，GPT-OSS-120B のみで有意（$r = 0.401$, $p = 0.0010$）であり，他の 3 教師では有意水準に達しなかった．

Openness（O）は，Qwen3-235B（$r = 0.350$, $p = 0.0060$），GPT-OSS-120B（$r = 0.345$, $p = 0.0088$），DeepSeek-V3（$r = 0.323$, $p = 0.0086$）の 3 教師で有意であったが，Sonnet4 では有意でなかった．

一般因子混入の可能性について: 上記の A/E/N/O における有意な結果の一部は，C に寄与する特徴量が他の次元にも影響している一般因子（general factor）の混入によるものである可能性がある．特に，GPT-OSS-120B が複数の次元で一貫して有意な結果を示している点は，このモデルが特徴量全体に対して感度が高い（あるいは次元間の分離が不十分である）可能性を示唆する．こ

の点の検証には，特徴量の次元間共有分散の分析や，部分相関による次元固有の寄与の分離が必要であり，今後の課題とする．

参考文献

[1] Hu, C. B., et al. (2025). Automated scoring of an ADOS-2 item using zero-shot large language models applied to clinical dialogues. *npj Digital Medicine*, 8, Article 133.

[2] Altozano, M. A., et al. (2026). Enhancing psychological assessments with open-ended questionnaires and large language models: An ASD case study. *IEEE Journal of Biomedical and Health Informatics*, 30(3), 1–12.

[3] Mun, S., et al. (2024). Automatic estimation of social communication severity in autistic children from speech using pre-trained language models. *arXiv preprint*, arXiv:2409.00158.

[4] Nakamura, Y., et al. (2025). ADOS-2 会話テキストからの ASD 分類: BERT 由来特徴量と LightGBM による検討. *SICE* 東北支部研究会資料, 353-9.